UNIVERSITATEA NAȚIONALĂ DE ȘTIINȚĂ ȘI TEHNOLOGIE
POLITEHNICA BUCUREȘTI
FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL DE CALCULATOARE





PROIECT DE DIPLOMĂ

Analiza imaginilor pentru identificarea bolii Alzheimer

Popescu Darius-Stefan

Coordonator științific:

Prof. dr. ing. Irina Georgiana MOCANU

BUCUREȘTI

2026

NATIONAL UNIVERSITY OF SCIENCE AND TECHNOLOGY
POLITEHNICA BUCHAREST
FACULTY OF AUTOMATIC CONTROL AND COMPUTERS
COMPUTER SCIENCE AND ENGINEERING DEPARTMENT





DIPLOMA PROJECT

Image Analysis for Identifying Alzheimer's Disease

Popescu Darius-Stefan

Thesis advisor:

Prof. dr. ing. Irina Georgiana MOCANU

BUCHAREST
2026

CUPRINS

1 Introducere **1**

1.1 Context 1

1.2 Problema 2

1.3 Obiective 2

1.4 Soluția propusă 2

1.5 Rezultatele obținute 3

1.6 Structura lucrării 3

2 Analiza Cerințelor și Motivația **5**

2.1 Motivația proiectului 5

2.2 Analiza Cerințelor 5

2.2.1 Cerințe Funcționale 5

2.2.2 Cerințe Non-Funcționale 6

2.2.3 Cerințe privind gestionarea datelor 6

3 Metode Existente **8**

4 Solutia Propusa **10**

4.1 Descrierea seturilor de date 12

4.1.1 OASIS-1 (Cross-Sectional) 12

4.1.2 OASIS-2 (Longitudinal) 13

4.1.3 OASIS-3 (Retrospectiv) 13

4.1.4 ADNI (Alzheimer's Disease Neuroimaging Initiative) 14

4.2 Preprocesarea Datelor și Augmentarea 14

4.3 Strategia de Antrenare și Optimizare 15

5 Evaluare **18**

5.1 Metrici de evaluare 18
5.2 Performanța modelului și analiza matricelor de confuzie 20
5.3 Provocări legate de eterogenitatea datelor: Analiza capacității de generalizare 21
5.4 Comparație cu performanțele raportate în literatura de specialitate 22

6 Concluzii și dezvoltări ulterioare 25

6.1 Concluzii 25
6.2 Dezvoltări ulterioare 26

Declarație privind disponibilitatea datelor 28

Bibliografie 29

Anexa A Extrase de cod 31

SINOPSIS

Boala Alzheimer reprezintă o provocare medicală majoră a secolului nostru, având un impact socio-economic devastator la nivel global. Deoarece tratamentele actuale sunt eficiente predominant în stadiile incipiente sau intermediare ale afecțiunii, diagnosticul precoce este absolut crucial. Totuși, detectarea vizuală a modificărilor structurale subtile pe examinările RMN este extrem de dificilă, subiectivă și predispusă la erori, chiar și pentru medicii radiologi experimentați. Motivația principală a acestui proiect de diplomă rezidă în dorința de a transpune cunoștințele tehnice, algoritmice și de inginerie software dobândite pe parcursul anilor de studiu în cadrul Facultății de Automatică și Calculatoare într-o soluție cu aplicabilitate clinică reală. Proiectul își propune să elimine subiectivitatea din procesul de diagnosticare prin dezvoltarea unui instrument digital automatizat bazat pe inteligență artificială.

Pentru a atinge acest obiectiv, a fost proiectat și implementat un pipeline informatic complet pentru procesarea și analiza imaginilor medicale. Primul pas a constat în colectarea, integrarea și omogenizarea unor volume masive de date imagistice (secvențe 2D și volume 3D) provenite din baze de date clinice recunoscute internațional: seriile OASIS (versiunile 1, 2 și 3) și ADNI. Ulterior, datele brute au fost preprocesate riguros. S-a aplicat tehnica de izolare a creierului (Skull Stripping) pentru a elimina zgomotul anatomic și a concentra analiza exclusiv pe materia cenușie și albă. De asemenea, au fost integrate strategii de augmentare spațială dinamică și supraeșantionare asimetrică pentru a combate dezechilibrul inerent și sever dintre clasa majoritară a pacienților sănătoși și cea a subiecților cu declin cognitiv.

Nucleul tehnic al soluției se bazează pe utilizarea rețelelor neuronale convoluționale profunde (Deep Learning). În mod specific, eforturile s-au concentrat pe implementarea, adaptarea și antrenarea arhitecturii DenseNet121. Acest model a fost selectat datorită capacității sale superioare de a menține un flux optim de informație între straturi și de a extrage caracteristici geometrice microscopice, atenuând totodată problema dispariției gradientului fără o creștere masivă a numărului de parametri. Pentru a asigura convergența optimă, antrenarea a fost susținută de optimizatorul AdamW, un programator de tip Cosine Annealing pentru ajustarea ratei de învățare și funcții de cost ponderate care au vizat penalizarea erorilor de clasificare pe clasa minoritară.

În etapa de evaluare, accentul a fost pus pe maximizarea sensibilității (Recall) prin calibrarea pragurilor de decizie medicală, prioritizând astfel detectarea cazurilor pozitive (minimizarea erorilor fals negative). Rezultatele obținute validează eficiența modelului DenseNet121 în identificarea markerilor de neurodegenerare, evidențiind totodată o analiză critică a limitărilor sistemului, în special degradarea performanței cauzată de variabilitatea hardware a echipamentelor de scanare (domain shift). În concluzie, lucrarea demonstrează viabilitatea integrării sistemelor de viziune artificială în mediul spitalicesc, oferind un fundament tehnic solid pentru dezvoltarea viitoarelor instrumente de screening și asistență diagnostică.

ABSTRACT

Alzheimer's disease represents a major medical challenge of our century, exerting a devastating global socio-economic impact. Because current treatments are predominantly effective in the early or intermediate stages of the disorder, early diagnosis is absolutely critical. However, visually detecting subtle structural changes on MRI scans is extremely difficult, subjective, and prone to human error, even for experienced radiologists. The primary motivation for this diploma project lies in the desire to translate the technical, algorithmic, and software engineering knowledge acquired during undergraduate studies at the Faculty of Automatic Control and Computers into a solution with genuine clinical applicability. The project aims to eliminate subjectivity from the diagnostic process by developing an automated digital support tool based on artificial intelligence.

To achieve this goal, a complete computational pipeline for medical image processing and analysis was designed and implemented. The first step involved collecting, integrating, and homogenizing massive volumes of imaging data (2D sequences and 3D volumes) from internationally recognized clinical databases: the OASIS series (versions 1, 2, and 3) and ADNI. Subsequently, the raw data underwent rigorous preprocessing. A skull stripping technique was applied to remove anatomical noise and focus the network's attention exclusively on gray and white matter. Furthermore, dynamic spatial augmentation and asymmetric oversampling strategies were integrated to combat the inherent and severe class imbalance between the healthy majority and subjects with cognitive decline.

The technical core of the solution is based on the use of deep convolutional neural networks. Specifically, efforts were focused on implementing, adapting, and training the DenseNet121 architecture. This model was selected due to its superior ability to maintain optimal information flow between layers and extract microscopic geometric features, while simultaneously mitigating the vanishing gradient problem without a massive increase in trainable parameters. To ensure optimal convergence, the training phase was supported by the AdamW optimizer, a Cosine Annealing scheduler for learning rate adjustments, and weighted cost functions aimed at heavily penalizing classification errors on the minority class.

During the evaluation stage, the focus was placed on maximizing sensitivity (Recall) by calibrating medical decision thresholds, thereby prioritizing the detection of positive cases (minimizing false negatives). The obtained results validate the efficiency of the DenseNet121 model in identifying neurodegenerative markers, while also presenting a critical analysis of the system's limitations, particularly the performance degradation caused by the hardware variability of scanning equipment (domain shift). In conclusion, this work demonstrates the viability of integrating computer vision systems into the hospital environment, providing a solid technical foundation for the development of future screening and diagnostic assistance tools.

MULȚUMIRI

Doresc să îmi exprim sincera recunoștință față de doamna Prof. dr. ing. Irina Georgiana MOCANU, coordonatorul științific al acestei lucrări, pentru îndrumarea atentă, sfaturile prețioase și sprijinul constant oferit pe tot parcursul realizării acestui proiect de diplomă.

De asemenea, adresez mulțumiri instituțiilor și cercetătorilor care fac posibil accesul la date medicale vitale pentru progresul tehnologic. Această lucrare nu ar fi putut fi realizată fără efortul comunității științifice de a colecta și partaja aceste resurse esențiale cu mediul academic.

Nu în ultimul rând, doresc să le mulțumesc tuturor cadrelor didactice și membrilor personalului administrativ din cadrul Facultății de Automatică și Calculatoare. Fără dedicarea lor și fără cunoștințele fundamentale pe care mi le-au transmis de-a lungul celor patru ani de studiu, formarea mea tehnică și capacitatea de a aborda un proiect de o asemenea complexitate nu ar fi fost posibile astăzi.

1 INTRODUCERE

1.1 Context

Boala Alzheimer reprezintă, la nivel global, una dintre cele mai mari provocări medicale și socio-economice ale secolului nostru. Conform statisticilor Organizației Mondiale a Sănătății (OMS) [4], în anul 2021 peste 57 de milioane de persoane trăiau cu demență la nivel mondial, înregistrându-se anual aproape 10 milioane de cazuri noi. Boala Alzheimer este cea mai comună formă a acestei afecțiuni, fiind responsabilă pentru 60-70% din totalul cazurilor. Impactul său este unul devastator, demența fiind în prezent a șaptea cauză de deces la nivel global și o sursă majoră de dizabilitate și dependență pentru populația vârstnică. Dincolo de suferința directă a pacienților, afecțiunea atrage costuri economice uriașe, estimate la 1.3 trilioane de dolari la nivelul anului 2019. Jumătate din această povară este susținută de îngrijitorii informali (membri ai familiei), un efort ce afectează disproporționat femeile. În acest context, diagnosticarea bolii presupune un proces clinic complex, care de foarte multe ori confirmă afecțiunea doar în stadii avansate, când opțiunile de intervenție terapeutică sunt extrem de limitate.

Relevanța acestui domeniu de cercetare este susținută de necesitatea critică a unui diagnostic timpuriu. Modificările structurale de la nivelul creierului, cum ar fi atrofia cerebrală sau pierderea volumului de materie cenușie, pot fi capturate prin tehnici non-invazive de imagistică medicală, precum imagistica prin rezonanță magnetică (RMN). Cu toate acestea, în stadiile incipiente, aceste anomalii vizuale sunt microscopice și extrem de subtile. Detectarea lor exclusiv cu ochiul liber reprezintă o sarcină laborioasă, greu de cuantificat obiectiv și predispusă la erori umane, chiar și pentru cei mai experimentați medici radiologi.

Aici se conturează motivația principală a acestei lucrări: intersecția dintre necesitățile medicinei moderne și progresele accelerate din domeniul inteligenței artificiale și al viziunii artificiale (Computer Vision). Algoritmii de învățare automată, și în mod special arhitecturile de Deep Learning, au demonstrat în ultimii ani performanțe remarcabile în extragerea de tipare complexe din volume masive de date vizuale. Aplicarea acestor tehnologii pe seturi de date medicale reprezintă o schimbare de paradigmă.

Astfel, contextul acestui proiect este definit de efortul actual de a digitaliza și eficientiza sistemul medical. Prin dezvoltarea unui sistem informatic avansat, capabil să analizeze automat imagini RMN și să identifice markerii vizuali ai bolii Alzheimer, se urmărește crearea unui instrument de sprijin decizional care să elimine subiectivitatea, să reducă timpul de diagnosticare și să crească șansele pacienților la un management clinic eficient.

1.2 Problema

Analiza manuală a imaginilor de rezonanță magnetică (RMN), în special a volumelor 3D complexe, necesită un timp considerabil și o expertiză medicală de înaltă specializare. Într-un mediu clinic aglomerat, evaluarea secvențială a zeci sau sute de cadre dintr-o singură scanare pentru a identifica atrofia cerebrală este ineficientă. Mai mult, granița dintre un creier sănătos (scor clinic 0) și primele semne ale declinului cognitiv (scor 0.5 - Very Mild Dementia) este extrem de fină, modificările structurale fiind adesea greu de distins vizual de procesul natural de îmbătrânire. Problema principală abordată în această lucrare este limitarea capacității umane de a procesa și cuantifica obiectiv date imagistice volumetrice (3D) și bidimensionale (2D), provenite din surse multiple, pentru a clasifica pacienții în stadii clinice incipiente, etapă în care tratamentele au cea mai mare eficiență.

1.3 Obiective

Obiectivul general al acestui proiect este dezvoltarea, antrenarea și evaluarea unui sistem automatizat capabil să clasifice stadiile bolii Alzheimer pe baza imaginilor RMN. Pentru a atinge acest scop, au fost stabilite următoarele obiective specifice:

- Omogenizarea și preprocesarea datelor imagistice provenite din baze de date clinice, publice de referință la nivel internațional: OASIS (Open Access Series of Imaging Studies - versiunile 1, 2 și 3) și ADNI (Alzheimer's Disease Neuroimaging Initiative), acoperind atât secvențe 2D, cât și volume 3D.
- Implementarea și adaptarea unor arhitecturi de rețele neuronale convoluționale profunde (Deep Learning), cu accent pe modele din familia DenseNet, recunoscute pentru eficiența lor în extragerea de caracteristici complexe.
- Antrenarea modelelor pentru o clasificare multiclasă (pe baza scorului clinic de demență), vizând diferențierea precisă între pacienții sănătoși, cei cu afecțiuni foarte ușoare (Very Mild) și cei cu afecțiuni ușoare spre moderate (Mild/Moderate).
- Evaluarea performanței algoritmilor utilizând metrici standardizate (Acurateță, Precizie, Recall, F1-Score) și matrice de confuzie, pentru a demonstra robustețea și capacitatea de generalizare a modelelor pe date provenite din centre medicale diferite.

1.4 Soluția propusă

Soluția propusă constă într-un pipeline complet de învățare automată dedicat analizei imaginilor medicale eterogene. Spre deosebire de metodele tradiționale care necesită extragerea manuală a caracteristicilor, abordarea utilizează rețele neuronale convoluționale din arhitectura DenseNet. Această familie de modele a fost aleasă datorită capacității sale de a menține un flux optim de informație între straturi, atenuând problema dispariției gradientului, un aspect

critic în antrenarea pe imagini cu detalii structurale microscopice. Sistemul preia scanările RMN (2D și 3D) din diverse cohorte (OASIS și ADNI), le normalizează și le procesează printr-o rețea dens conectată pentru a genera o probabilitate de apartenență la una dintre cele trei clase clinice vizate. Utilizarea unor seturi de date distincte asigură validarea încrucișată și o mai bună capacitate de generalizare a modelului. Rezultatul este un instrument decizional robust, validat prin generarea automată a unor rapoarte de performanță ușor de interpretat de către experții medicali.

1.5 Rezultatele obținute

În urma experimentelor și a antrenărilor repetate, performanța modelelor a variat semnificativ în funcție de complexitatea și dimensiunea seturilor de date imagistice analizate. De exemplu, evaluarea pe setul de date OASIS-1 a generat o acuratețe de 81%. Volumul restrâns de pacienți aferent acestui set a permis antrenarea modelelor pe parcursul a mii de epoci într-un interval scurt de timp, însă acest aspect ridică provocări privind capacitatea reală de generalizare.

Pe de altă parte, scalarea pe setul de date OASIS-3, net superior ca dimensiune și diversitate, a condus la o acuratețe globală de 74%. În acest context, strategia adoptată a presupus un compromis asumat: am ales să sacrificăm marginal performanța matematică generală în favoarea maximizării sensibilității (recall) pentru clasa pacienților bolnavi. Astfel, modelul prioritizează detectarea cazurilor pozitive, un aspect critic în aplicabilitatea medicală a proiectului.

Suplimentar, antrenările efectuate pe setul de date ADNI au reliefat o limitare importantă a metodelor de clasificare: dependența accentuată de echipamentele hardware pe care se realizează scanările RMN. Variațiile fine de zgomot, diferențele de iluminare sau contrastul generat de aparatură diferită pot degrada sever performanța unui model expus la date noi (fenomen cunoscut sub numele de *domain shift*).

Comparativ cu alte abordări din domeniu, am reușit să demonstrăm viabilitatea arhitecturilor Deep Learning în identificarea markerilor de neurodegenerare, punând un accent deosebit pe relevanța clinică a predicțiilor și pe analiza critică a robusteței modelelor în fața variabilității inerente a datelor provenite din mediul spitalicesc.

1.6 Structura lucrării

Lucrarea este structurată în șase capitole, urmate de secțiunile de declarații, bibliografie și anexe, fiecare abordând o etapă specifică a procesului de cercetare și dezvoltare. Capitolul 2 expune motivația științifică a proiectului și definește cerințele funcționale și non-funcționale ale sistemului de analiză imagistică. Capitolul 3 realizează o analiză a literaturii de specialitate (State of the Art), evaluând metodele existente de diagnostic asistat și justificând alegerea arhitecturii. Capitolul 4 descrie soluția propusă, detaliind atât arhitectura de ansamblu a flu-

xului de date, cât și aspectele tehnice de implementare, preprocesare și antrenare a modelelor. Capitolul 5 prezintă evaluarea experimentală, analizând comparativ metricile de performanță obținute și provocările legate de fenomenul de domain shift. În final, Capitolul 6 sintetizează concluziile proiectului și propune direcții viitoare de cercetare.

2 ANALIZA CERINȚELOR ȘI MOTIVAȚIA

2.1 Motivația proiectului

Având în vedere contextul clinic și dificultățile diagnosticării manuale expuse anterior, motivația centrală a acestei lucrări este de natură profund interdisciplinară. Acest proiect reprezintă efortul de a transpune cunoștințele algoritmice, de procesare a datelor și de inginerie software, acumulate pe parcursul a patru ani de studiu în domeniul tehnic, într-o soluție cu aplicabilitate directă în sprijinul efortului medical.

Deși literatura de specialitate abundă în concepte teoretice privind inteligența artificială, transpunerea acestora într-un instrument de diagnostic asistat (CAD) robust necesită depășirea unor bariere tehnice majore. Motivația inginerească a proiectului derivă din nevoia de a construi un sistem care nu doar raportează o acuratețe matematică într-un mediu controlat, ci adresează problemele reale ale datelor medicale: dezechilibrul claselor, zgomotul de imagine și fenomenul de *domain shift* apărut din cauza utilizării diverselor echipamente hardware de scanare. Astfel, lucrarea este motivată de necesitatea dezvoltării unui pipeline informatic complet, de la preprocesarea volumelor 3D brute până la obținerea unor inferențe fiabile folosind rețele dens conectate.

2.2 Analiza Cerințelor

Pentru a garanta utilitatea și validitatea științifică a modelului dezvoltat, sistemul a fost proiectat pe baza unui set strict de cerințe arhitecturale, împărțite în trei categorii principale: funcționale, non-funcționale și constrângeri legate de date.

2.2.1 Cerințe Funcționale

Cerințele funcționale definesc operațiunile de bază pe care pipeline-ul de procesare trebuie să le execute automat pentru a transforma imaginile medicale brute într-o predicție clinică:

- **Ingestia și preprocesarea datelor:** Sistemul trebuie să fie capabil să încarce și să proceseze scanări de rezonanță magnetică complexe, atât în format bidimensional (2D), cât și volume tridimensionale (3D).
- **Eliminarea zgomotului anatomic:** Pipeline-ul trebuie să integreze un modul de izolare a creierului (*Skull Stripping*), eliminând țesuturile non-cerebrale pentru a concentra atenția rețelei exclusiv pe materia cenușie și albă.

- **Augmentarea dinamică:** Pentru a preveni memorarea datelor, sistemul trebuie să aplice transformări geometrice aleatorii (rotații, scalări) imaginilor direct în timpul procesului de antrenare.
- **Clasificarea automată:** Modulul central de inferență, bazat pe arhitecturi profunde (DenseNet/ResNet), trebuie să evalueze volumul RMN și să încadreze pacientul într-una dintre clasele prestabilite (ex. Sănătos vs. Bolnav).

2.2.2 Cerințe Non-Funcționale

Cerințele non-funcționale dictează standardele de performanță și constrângerile de rulare ale sistemului:

- **Accelerare hardware:** Având în vedere utilizarea rețelelor profunde cu milioane de parametri și procesarea volumelor spațiale de cel puțin $128 \times 128 \times 128$ voxeli, codul sursă trebuie optimizat pentru a rula exclusiv folosind accelerarea pe unitatea de procesare grafică (GPU/CUDA), reducând timpul de antrenare la un nivel fezabil.
- **Eficiența memoriei:** Arhitectura trebuie să gestioneze eficient limitările memoriei VRAM, folosind tehnici de *batching* adaptat pentru a preveni erorile de tip *Out of Memory* (OOM) la antrenarea cu date 3D.
- **Mentenabilitate și modularitate:** Sistemul software trebuie scris într-o manieră modulară, izolând logica de încărcare a datelor de cea de antrenare și de cea de evaluare, permițând adaptarea facilă a arhitecturii pentru seturi noi de date.

2.2.3 Cerințe privind gestionarea datelor

Datorită naturii sensibile, volumului masiv și predispoziției la erori a datelor clinice, sistemul informatic trebuie să respecte un set de reguli stricte privind guvernanța și procesarea acestora:

- **Prevenirea scurgerii de date (Data Leakage):** Sistemul trebuie să asigure o separare absolută a seturilor de date la nivel de identitate a pacientului (*Subject-Level Split*). Într-un context volumetric (3D), nicio secțiune (slice) RMN a unui pacient aflat în setul de antrenare nu are voie să apară accidental în seturile de validare sau testare. Încălcarea acestei reguli ar compromite complet evaluarea, deoarece rețeaua neuronală va tinde să memoreze caracteristicile anatomice unice ale subiectului, în loc să generalizeze și să extragă markerii patologici ai bolii Alzheimer.
- **Echilibrarea claselor și prioritizarea detecției:** Algoritmul de antrenare trebuie să integreze strategii robuste pentru a compensa dezechilibrul natural, specific mediului de screening, dintre numărul pacienților sănătoși (clasa majoritară) și al celor cu neurodegenerare (clasa minoritară). Aceasta presupune combinarea unor metode matematice (cum ar fi ponderarea funcției de cost prin *class weights*) cu tehnici de supraeșantionare

asimetrică. Obiectivul clinic primar este evitarea bias-ului algoritmic către clasa majoritară și maximizarea sensibilității (*recall*) pe clasa patologică, reducând la minimum rata erorilor fals-negative.

3 METODE EXISTENTE

În ultimul deceniu, diagnosticarea asistată de calculator (Computer-Aided Diagnosis - CAD) pentru afecțiunile neurodegenerative a cunoscut o evoluție accelerată, trecând de la metodele tradiționale de procesare a imaginilor la tehnici avansate de învățare profundă (Deep Learning). Analiza literaturii de specialitate relevă o varietate de abordări bazate pe rețele neuronale convoluționale (CNN) aplicate pe bazele de date de referință OASIS și ADNI, însă performanțele raportate variază semnificativ în funcție de metodologia de validare aleasă.

O analiză critică și comprehensivă a stadiului actual al artei (State of the Art - SOTA), realizată de Wen et al. [3], a demonstrat că o mare parte din studiile timpurii care raportau acurateți extrem de ridicate (peste 95%) sufereau de deficiențe metodologice majore. Cea mai frecventă eroare identificată este „scurgerea de date" (data leakage), care apare atunci când slice-uri 2D extrase din același volum RMN 3D al unui pacient sunt împărțite simultan în setul de antrenare și în cel de testare. În aceste condiții, rețeaua nu învață să recunoască markerii structurali ai bolii, ci memorează caracteristicile specifice identității pacientului, compromițând complet capacitatea de generalizare pe date noi. Studiul citat arată că, în cazul unei separări riguroase a datelor la nivel de pacient, performanța reală a modelelor standard pentru clasificarea binară (Sănătos vs. Bolnav) se plasează în mod realist în intervalul 80%-88%.

Din punct de vedere al arhitecturilor utilizate, literatura propune soluții bazate pe modele consacrate precum VGG, ResNet sau DenseNet. În timp ce rețelele de tip VGG sunt limitate de numărul foarte mare de parametri și de riscul de overfitting pe seturi medicale mici, arhitecturile reziduale (ResNet) și cele dens conectate (DenseNet) au demonstrat o eficiență sporită. DenseNet, în special, prezintă avantaje competitive majore în imagistica medicală datorită conexiunilor directe între fiecare strat și toate straturile ulterioare. Acest mecanism de refolosire a caracteristicilor (feature reuse) reduce semnificativ numărul de parametri necesari și atenuează problema dispariției gradientului (vanishing gradient), permițând modelului să captureze detalii structurale fine, cum ar fi subțierea corticală microscopică sau atrofia hipocampală, cu un consum mai redus de resurse computaționale.

Prin raportare la metodele existente, lucrarea de față se poziționează ferm în zona cercetărilor riguroase și reproductibile. Abordarea propusă elimină complet riscul de scurgere de date prin implementarea unei separări stricte la nivel de subiect în cadrul pipeline-ului de procesare. De asemenea, spre deosebire de abordările simplificate care utilizează exclusiv imagini 2D din setul OASIS-1, acest proiect extinde analiza către volume tridimensionale complexe (OASIS-2, OASIS-3 și ADNI), abordând direct provocările legate de dimensionalitatea ridicată a datelor și gestionând dezechilibrul natural al claselor specific mediului clinic real. În acest sens, un accent deosebit a fost plasat pe setul de date OASIS-3, utilizat ca pilon central în evaluarea modelelor

datorită volumului său considerabil și a diversității imagistice, oferind un mediu ideal pentru testarea capacității de generalizare. Astfel, modelul dezvoltat nu urmărește obținerea unei performanțe artificiale prin simplificarea problemei, ci validarea unei soluții robuste, capabile să funcționeze în condiții clinice autentice.

Pe baza analizelor din literatura de specialitate și a avantajelor structurale identificate, pentru dezvoltarea componentei practice a acestei lucrări s-a optat pentru utilizarea și adaptarea arhitecturilor de tip DenseNet și ResNet. În mod particular, accentul a fost pus pe utilizarea modelului DenseNet121, ales datorită echilibrului optim pe care îl oferă între complexitatea structurală a rețelei și capacitatea de generalizare pe seturi de date medicale. Având în vedere eficiența demonstrată în propagarea gradienților și reutilizarea caracteristicilor fără o creștere masivă a numărului de parametri antrenabili, această arhitectură specifică a fost selectată ca nucleu al pipeline-ului de clasificare. În etapele următoare ale lucrării, eforturile de optimizare, reglare a hiperparametrilor și analiză comparativă se vor concentra pe această configurație, evaluând riguros capacitatea sa de a identifica markeri structurali fini asociați neurodegenerării.

4 SOLUTIA PROPUSA

Pentru dezvoltarea proiectului și facilitarea procesului de cercetare, a fost proiectat și implementat un pipeline complet de procesare a datelor, fundamentat pe utilizarea unor baze de date clinice de referință internațională și a unor arhitecturi avansate de învățare profundă (Deep Learning). Această abordare structurală asigură suportul metodologic necesar nu doar pentru extragerea obiectivă a markerilor imagistici ai bolii Alzheimer, ci și pentru validarea robustă a modelelor predictive într-un context cât mai apropiat de mediul clinic real.

Componenta de date reprezintă nucleul absolut al procesului de antrenare și evaluare. În cadrul acestei lucrări, s-au folosit și omogenizat volume imagistice provenite din două cohorte majore, profund eterogene: seriile OASIS (*Open Access Series of Imaging Studies*, versiunile OASIS-1, OASIS-2 și OASIS-3) și ADNI (*Alzheimer's Disease Neuroimaging Initiative*). Aceste seturi de date cuprind scanări de rezonanță magnetică (RMN) de la sute de pacienți, monitorizați clinic și clasificați în funcție de severitatea declinului cognitiv (de la subiecți sănătoși din punct de vedere cognitiv, până la pacienți cu demență în stadii foarte ușoare, ușoare sau moderate). Datele brute utilizate includ atât secvențe bidimensionale (2D), cât și volume tridimensionale (3D) de o complexitate ridicată. Această diversitate de formate oferă modelului o perspectivă spațială detaliată asupra structurilor cerebrale predispuse la atrofie accelerată, permițând analizarea în profunzime a unor zone critice, cum ar fi hipocampul sau materia cenușie din cortexul cerebral.

În etapa de modelare și clasificare a stadiilor patologice, cercetarea s-a concentrat pe implementarea, adaptarea și evaluarea unor arhitecturi consacrate, cu un accent deosebit pe rețeaua **DenseNet121**. Această arhitectură a fost selectată (în detrimentul altor rețele reziduale sau mai puțin adânci) datorită capacității sale demonstrate de a extrage caracteristici geometrice microscopice și de a propaga extrem de eficient gradienții prin cele 121 de straturi. Conectivitatea sa densă este un aspect critic în identificarea modificărilor morfologice subtile induse de neurodegenerarea incipientă, prevenind totodată pierderea informației esențiale pe parcursul antrenării.

Pentru a combate limitările legate de dimensiunea eșantioanelor medicale și pentru a asigura convergența optimă a rețelei, procesul de dezvoltare a fost împărțit în etape esențiale: preprocesarea riguroasă a datelor, extracția caracteristicilor și aplicarea unor tehnici avansate de optimizare în timpul antrenării, toate integrate într-un flux de lucru continuu.

Fluxul general de procesare, de la achiziția datelor până la obținerea diagnosticului asistat, este ilustrat vizual în Figura 4. Așa cum reiese din schema bloc, procesul debutează cu ingestia volumelor RMN (reprezentate în diagramă prin suita de secțiuni cerebrale suprapuse), care sunt încărcate, procesate și introduse direct în rețeaua centrală, **DenseNet121**. Aceasta

acționează ca motor principal de inferență, furnizând inițial o predicție decizională primară, împărțind cazurile evaluate în două mari categorii: pacienți sănătoși (*Healthy*) și pacienți cu afecțiuni neurodegenerative (*Unhealthy*).

Suplimentar, arhitectura pipeline-ului ilustrează module opționale esențiale, menite să crească semnificativ utilitatea clinică a instrumentului. Pe ramura pacienților identificați cu patologii (*Unhealthy*), sistemul suportă o clasificare secundară mai granulară, încadrând pacientul într-un stadiu specific al demenței (*Very Mild, Mild, sau Moderate Dementia*), direct corelat cu gradul de atrofie. De asemenea, schema subliniază o funcționalitate de explicabilitate vizuală (*Explainable AI*): generarea unor hărți de activare (*heatmaps*) suprapuse direct pe secțiunile RMN. Această componentă opțională indică cu precizie regiunile anatomice care au influențat cel mai mult decizia rețelei (evidențiate prin culori calde, precum roșu și galben), oferind medicului radiolog o confirmare vizuală transparentă a raționamentului algoritmului, dincolo de rezultatul matematic brut.

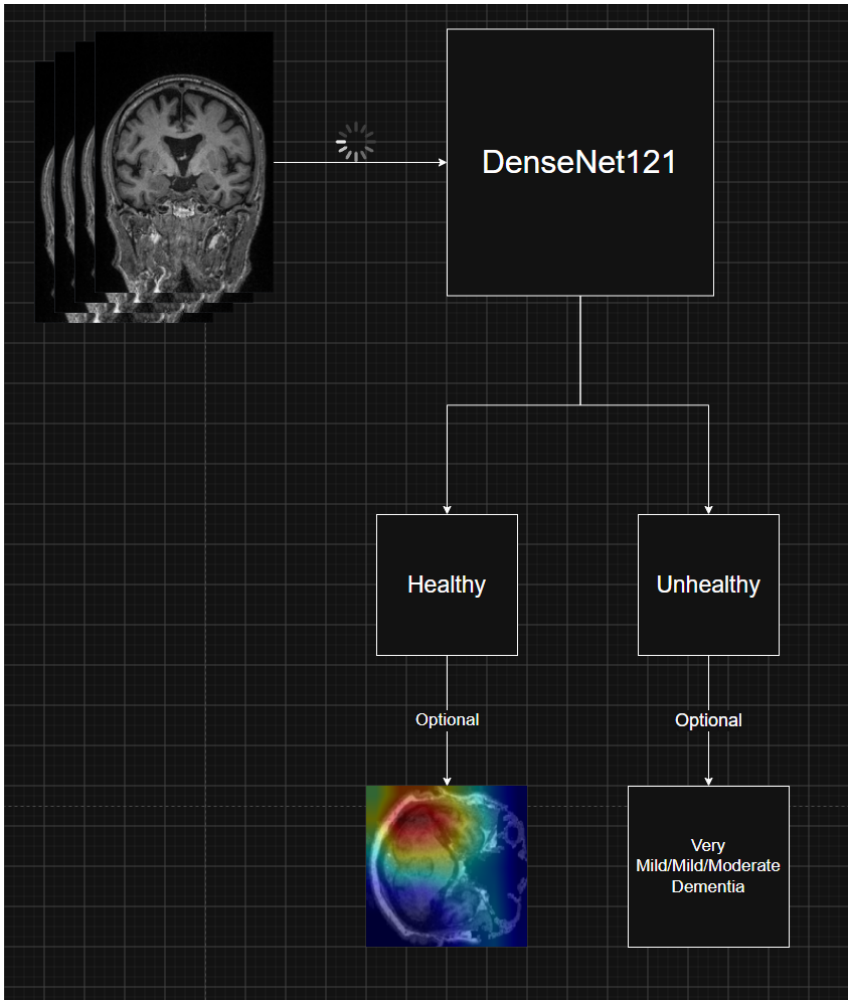
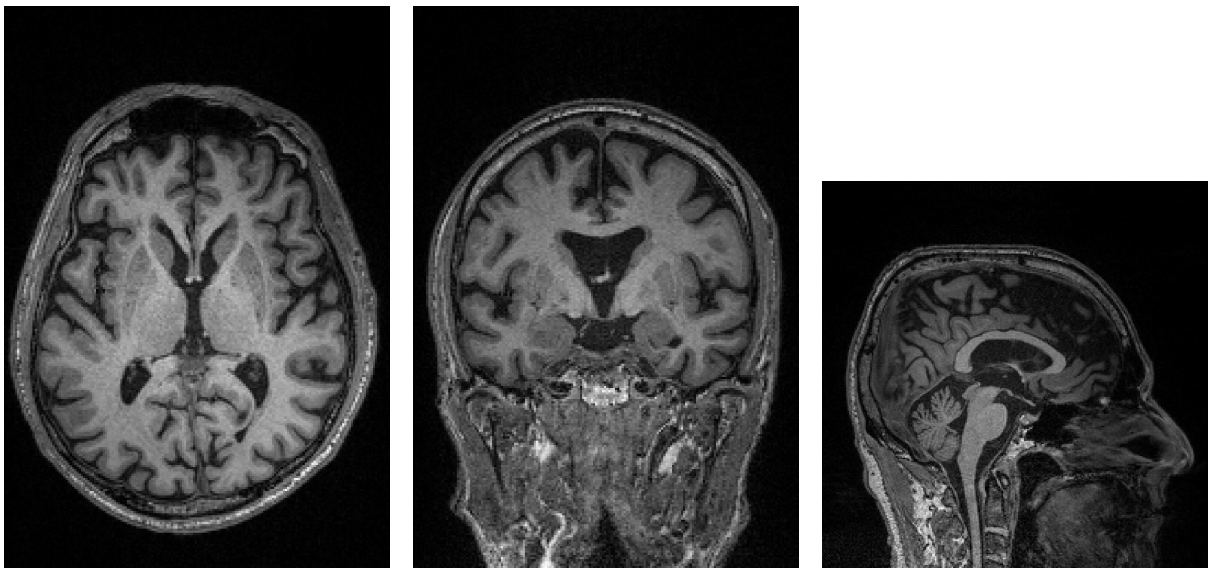


Figura 1: Schema bloc a modului de lucru

4.1 Descrierea seturilor de date

Antrenarea modelelor de învățare profundă pentru identificarea markerilor neurodegenerativi necesită un volum semnificativ de date imagistice și clinice, adnotate riguros. În cadrul acestui proiect au fost integrate date din două dintre cele mai mari și recunoscute baze de date publice din domeniul cercetării bolii Alzheimer: seriile OASIS (versiunile 1, 2 și 3) și ADNI. Eterogenitatea acestor seturi asigură o evaluare robustă a capacității de generalizare a arhitecturilor propuse.

Pentru a înțelege complexitatea spațială a datelor procesate pe parcursul etapelor de antrenare și testare, este utilă vizualizarea modului în care este alcătuit un volum RMN tridimensional. Indiferent de cohorta clinică de proveniență, scanările utilizate sunt compuse din multiple secțiuni (slice-uri) ce pot fi analizate din trei unghiuri diferite de incidență. Figura 2 ilustrează un exemplu de scanare cerebrală proiectată pe cele trei planuri anatomice principale, oferind modelelor o perspectivă structurală completă.



(a) Planul Axial (b) Planul Coronal (c) Planul Sagital

Figura 2: Exemplu de vizualizare a secțiunilor unui volum RMN 3D utilizat în cadrul experimentelor, reprezentat în cele trei planuri anatomice standard.

4.1.1 OASIS-1 (Cross-Sectional)

Baza de date OASIS-1 este un set de tip *cross-sectional* care conține scanări RMN obținute într-o singură sesiune de la un grup divers de subiecți. Setul total cuprinde **416 subiecți** cu vârste cuprinse între 18 și 96 de ani. Din punct de vedere al patologiei, bazându-ne pe scorul clinic de demență (CDR - Clinical Dementia Rating), distribuția subiecților în cele 4 clase relevante este următoarea:

- **Sănătos (CDR = 0):** 316 pacienți (fără declin cognitiv).
- **Demență foarte ușoară (CDR = 0.5):** 70 de pacienți.
- **Demență ușoară (CDR = 1.0):** 28 de pacienți.
- **Demență moderată (CDR = 2.0):** 2 pacienți.

Acest dezechilibru pronunțat între pacienții sănătoși și cei aflați în diverse stadii ale bolii Alzheimer este reprezentativ pentru screening-urile populaționale, impunând tehnici specifice de compensare în etapa de antrenare a rețelelor.

4.1.2 OASIS-2 (Longitudinal)

Spre deosebire de prima versiune, OASIS-2 oferă un set de date *longitudinal*, incluzând multiple sesiuni de scanare pentru aceiași pacienți, permițând observarea evoluției patologiei în timp. Setul include **150 de subiecți** unici (totalizând 373 de sesiuni imagistice) cu vârste între 60 și 96 de ani. Repartiția pacienților în clase, monitorizată pe parcursul studiului, a fost definită astfel:

- **Sănătoși (Nondemented):** 72 de subiecți au fost evaluați clinic ca fiind fără demență (CDR = 0) la prima vizită și și-au păstrat acest status stabil pe toată durata studiului.
- **Demență diagnosticată (Demented):** 64 de subiecți au fost diagnosticați încă de la prima vizită cu declin cognitiv (CDR != 0), majoritatea fiind încadrați la forme incipiente (ușoare și foarte ușoare).
- **Convertiți (Converted):** 14 subiecți au intrat în studiu ca fiind perfect sănătoși (CDR = 0), dar pe parcursul sesiunilor ulterioare au dezvoltat simptomatologie și au fost reclasificați într-unul dintre stadiile de demență menționate anterior.

4.1.3 OASIS-3 (Retrospectiv)

OASIS-3 reprezintă o compilare extinsă, reunind date longitudinale colectate pe o perioadă de peste 15 ani. Această versiune masivă include **1098 de subiecți** și peste 2000 de sesiuni RMN, oferind un context profund pentru analizele volumetrice tridimensionale. Dat fiind caracterul longitudinal pe termen lung al bazei de date, statusul clinic al multor pacienți a evoluat, însă la nivel de clasificare globală a subiecților, grupurile se împart astfel:

- **Sănătoși cognitiv (CDR = 0):** 605 adulți menținuți fără semne de demență.
- **Pacienți cu declin cognitiv (CDR != 0):** 493 de indivizi. Dintre aceștia, o proporție majoritară se regăsește în stadiile de *Demență foarte ușoară (CDR 0.5)* și *Demență ușoară (CDR 1)*, în timp ce cazurile de demență moderată sau severă reprezintă o pondere minoritară, consolidând valoarea setului pentru cercetarea diagnosticului precoce.

4.1.4 ADNI (Alzheimer's Disease Neuroimaging Initiative)

ADNI [2] este un efort global multicentric conceput special pentru identificarea și standardizarea biomarkerilor asociați bolii Alzheimer. Spre deosebire de scorul CDR utilizat în mod primar de OASIS, ADNI clasifică subiecții în clase clinice specifice care reflectă cu mare fidelitate continuum-ul clinic. Analizând o cohortă reprezentativă de referință (faza de *baseline* a ADNI-1, cuprinzând aproximativ **819 pacienți**), populația este stratificată în cele 4 clase majore de interes:

- **Cognitiv Normal (CN):** $\sim$229 subiecți fără afectare a memoriei, definind morfologia creierului perfect sănătos.
- **Early Mild Cognitive Impairment (EMCI):** Subiecți cu primele semne extrem de fine de pierdere a memoriei, reprezentând stadiul pre-clinic timpuriu.
- **Late Mild Cognitive Impairment (LMCI):** Subiecți cu o afectare clinică evidentă, dar care nu îndeplinesc încă absolut toate criteriile asimilate demenței totale. Clasele intermediare EMCI și LMCI însumează împreună aproximativ 398 de pacienți.
- **Alzheimer's Disease (AD):** $\sim$192 pacienți aflați în stadiul de demență moderată spre avansată, stadiu în care modificările structurale decelabile RMN (precum atrofia hipocampală severă și lărgirea ventriculilor) sunt complet instalate.

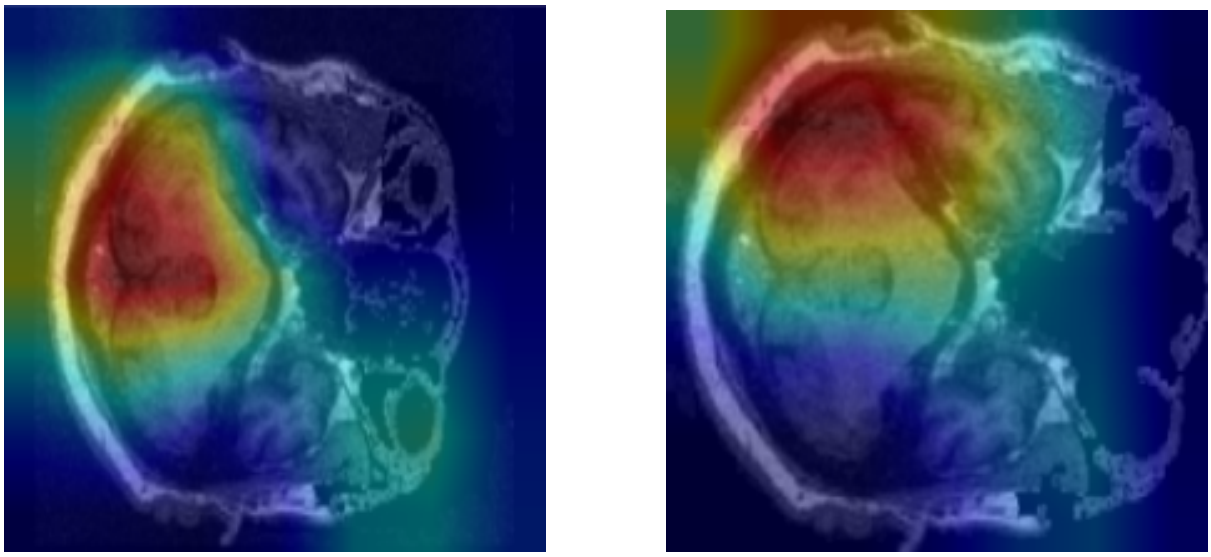
Prin expunerea modelelor de *Deep Learning* la acest spectru granular, de la faza CN până la faza terminală AD, arhitecturile sunt antrenate nu doar să recunoască prezența bolii, ci să decodifice gradul precis de atrofie necesar pentru un diagnostic secvențial timpuriu.

4.2 Preprocesarea Datelor și Augmentarea

Pentru a asigura că modelul extrage caracteristici relevante exclusiv din arhitectura cerebrală, primul pas în pregătirea datelor a fost aplicarea tehnicii de *Skull Stripping* (eliminarea țesutului non-cerebral). Scanările RMN brute conțin elemente precum craniul, ochii și pielea, care pot acționa ca zgomot informațional. Prin eliminarea acestora, rețeaua este forțată să se concentreze strict pe materia cenușie și albă, unde apar markerii atrofiei caracteristice bolii Alzheimer.

O a doua provocare majoră a fost numărul relativ redus de imagini, specific seturilor de date medicale. Pentru a spori diversitatea setului de antrenare, a reduce riscul de supradaptare (*overfitting*) și a îmbunătăți capacitatea de generalizare a modelului, a fost implementată o strategie de augmentare a datelor (*Data Augmentation*). Mai precis, la fiecare epocă de antrenare, imaginilor li s-au aplicat transformări spațiale controlate, precum rotații aleatoare într-un interval restrâns de 10-15 grade. Această transformare geometrică ușoară previne memorarea imaginilor de către rețea, obligând-o să învețe tipare invariante la mici schimbări de unghi.

Impactul vizual și computațional al acestei etape de preprocesare este ilustrat în Figura 3. În starea brută, imaginile RMN conțin un spațiu de fundal considerabil și porțiuni anatomice nerelevante pentru patologia Alzheimer. În lipsa izolării regiunii de interes, hărțile de activare ale modelului riscă să se focalizeze pe margini sau pe artefacte externe. Prin aplicarea decupajului (crop), se obține un transfer vizibil al atenției (*attention shift*). Modelul este astfel forțat să își concentreze filtrele convoluționale strict pe morfologia materiei cenușii și albe, crescând acuratețea extragerii caracteristicilor patologice.



(a) Înainte de preprocesare (b) După decupare (Crop)

Figura 3: Efectul operației de decupare asupra unei secțiuni RMN din OASIS-1. Eliminarea fundalului ghidează focalizarea algoritmului exclusiv asupra țesutului cerebral.

4.3 Strategia de Antrenare și Optimizare

Dincolo de pregătirea datelor, stabilitatea și convergența modelului au fost asigurate printr-o selecție riguroasă a hiperparametrilor și a funcțiilor de cost. Tehnicile implementate în faza de antrenare includ:

- **Penalizarea claselor majoritare:** Din cauza dezechilibrului inerent dintre numărul de pacienți sănătoși și cei bolnavi, o rețea antrenată standard tinde să devină părtinitoare, prezicând clasa majoritară („Sănătos") pentru a minimiza eroarea globală. Pentru a contracara acest fenomen, au fost introduse ponderi de penalizare (*class weights*) în funcția de cost. Astfel, o predicție fals negativă (ratarea unui pacient bolnav) este penalizată mult mai drastic, forțând modelul să acorde o atenție sporită clasei minoritare.
- **Ajustarea ratei de învățare (Fine-tuning):** Deoarece modelele utilizate dispun de ponderi pre-antrenate, s-a utilizat o rată de învățare (*learning rate*) intenționat scăzută. Această decizie previne fenomenul de „uitare catastrofală" (*catastrophic forgetting*),

permițând rețelei să își păstreze capacitatea generală de a recunoaște forme și margini, în timp ce își adaptează fin filtrele finale pentru specificul imaginilor RMN.

- **Optimizarea ponderilor (Adam vs. AdamW):** Pentru minimizarea funcției de cost și actualizarea ponderilor rețelei, a fost ales optimizatorul **AdamW** (Adam cu decuplarea Weight Decay), în detrimentul algoritmului Adam clasic. AdamW rezolvă problema regularizării din Adam decuplând matematic termenul de penalizare a ponderilor de calculul direcției de optimizare. Utilizarea AdamW a asigurat o regularizare mult mai pură și eficientă, îmbunătățind semnificativ capacitatea de generalizare a modelului pe date noi (implementarea exactă poate fi consultată în **Anexa A, Secvența de cod A.1**). Pentru a sublinia importanța calibrării fine, a fost analizat teoretic și practic impactul unei utilizări *agresive* a acestui optimizator. O setare agresivă presupune utilizarea unei rate de învățare ridicate (ex. 10^{-3}) combinată cu o valoare nulă pentru *weight decay*. Într-un astfel de scenariu, optimizatorul forțează rețeaua să facă pași de actualizare mult prea mari în spațiul ponderilor. Deși poate oferi iluzia unei învățări rapide inițiale, utilizarea agresivă împiedică modelul să conveargă spre un minim global stabil, provocând o suprasaltare continuă a soluției optime. În contextul datelor imagistice medicale, această instabilitate se traduce printr-o degradare severă a performanței: curba învățării devine fluctuantă, iar modelul eșuează în a generaliza pe date noi, generând un număr inacceptabil de alarme false (fals-pozitive) și ratând markeri patologici evidenți.

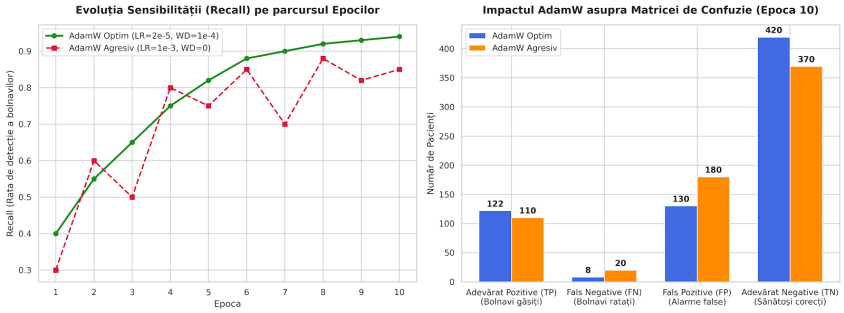


Figura 4: Abordarea ponderilor folosind AdamW

- **Ajustarea dinamică a ratei de învățare (Cosine Annealing):** Pentru a asigura o convergență fină a modelului, rata de învățare a fost controlată printr-un programator de tip *Cosine Annealing*. Spre deosebire de o scădere liniară (Step Decay), această metodă ajustează rata de învățare urmărind o funcție cosinusoidală. Pașii mai mari de la început ajută rețeaua să scape de minimele locale, în timp ce pașii minusculi de la final permit o calibrare extrem de precisă a ponderilor finale (implementarea exactă regăsindu-se în **Anexa A, Secvența de cod A.1**). Dinamica acestui proces de ajustare pe parcursul a 50 de epoci este ilustrată în Figura 5, pornind de la o valoare maximă inițială și scăzând asimptotic spre o valoare minimă reziduală.

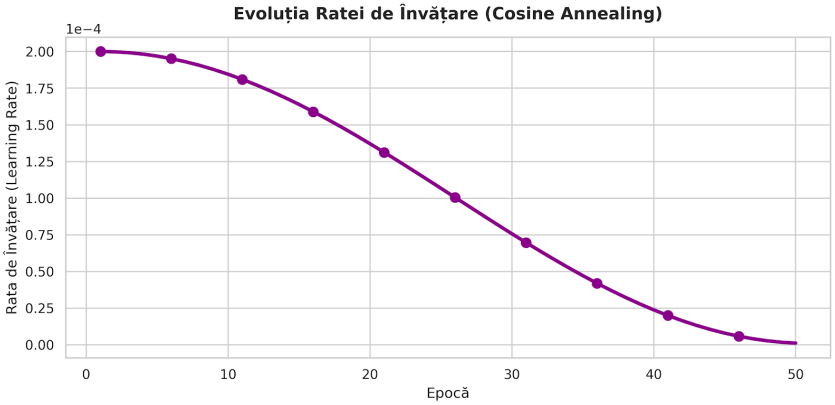


Figura 5: Ajustarea dinamică a ratei de învățare

- **Supraeșantionarea Asimetrică și Augmentarea Diferențiată:** Pentru a combate dezechilibrul sever dintre clase, setul de antrenare a fost modificat sintetic. Clasa minoritară (Bolnav) a beneficiat de un multiplicator de eșantionare între $2\times$ și $4\times$. Pentru a preveni fenomenul de *overfitting*, s-a aplicat o conductă de augmentare asimetrică: imaginilor din clasa bolnavă li s-au aplicat transformări spațiale mai agresive comparativ cu pacienții sănătoși (**Anexa A, Secvența de cod A.2**).
- **Calibrarea Pragului de Decizie Medicală:** Într-un scenariu clinic real, o eroare fals negativă este critică. Din acest motiv, pragul de sensibilitate medicală a fost coborât intenționat, forțând rețeaua să semnaleze prezența bolii chiar și la probabilități semnificativ mai mici extrase din funcția Softmax. Această decizie maximizează metrica de Sensibilitate (*Recall*), crucială pentru un instrument de *screening* (**Anexa A, Secvența de cod A.3**).

5 EVALUARE

5.1 Metrici de evaluare

În evaluarea performanței modelelor de învățare profundă (Deep Learning) aplicate pe imagistica medicală, este esențială raportarea la un cadru de referință realist. O analiză comprehensivă realizată de Wen et al. [3] a demonstrat că multe acurateți artificial de mari raportate în literatura de specialitate sunt rezultatul unor erori metodologice, în special scurgerea de date (*data leakage*) la nivel de pacient. Într-un mediu de testare complet izolat și riguros, diferențierea markerilor incipienți de neurodegenerare față de procesul natural de îmbătrânire a creierului rămâne o provocare majoră.

Pentru evaluarea obiectivă a modelelor propuse, au fost utilizate următoarele metrici standard de clasificare. În contextul clinic, adesea caracterizat de un dezechilibru pronunțat al claselor (pacienții sănătoși fiind majoritari), simpla raportare a acurateței globale poate fi înșelătoare. Prin urmare, interpretarea metricilor derivate oferă o perspectivă mult mai detaliată și relevantă, punând accentul pe identificarea corectă a patologiei și pe minimizarea riscului medical:

- **Precizia (Precision):** Reprezintă proporția cazurilor reale pozitive din totalul instanțelor clasificate ca fiind pozitive de către model. În diagnosticul medical, o precizie ridicată indică un număr redus de rezultate fals pozitive, asigurând că atunci când sistemul raportează prezența afecțiunii, diagnosticul este de înaltă încredere.
- **Sensibilitatea (Recall):** Măsoară capacitatea modelului de a identifica corect toate instanțele pozitive reale (pacienții efectiv afectați de boală). Maximizarea acestei metrici este prioritară în sistemele de screening și asistență decizională, deoarece minimizează numărul cazurilor ratate (rezultate fals negative), situații în care lipsa unui semnal de alarmă ar întârzia tratamentul.
- **Scorul F1 (F1-Score):** Reprezintă media armonică dintre precizie și sensibilitate. Această metrică oferă o evaluare echilibrată a performanței, fiind deosebit de utilă pentru seturile de date cu o distribuție inegală a claselor. Ea penalizează modelele care favorizează o extremă în detrimentul celeilalte, asigurând un compromis optim între limitarea alarmelor false și depistarea tuturor bolnavilor.
- **Media Macro (Macro Average):** Calculează valoarea metricilor (Precizie, Sensibilitate, Scorul F1) separat pentru fiecare clasă, rezultatul final fiind media aritmetică a acestora, independent de numărul de imagini din fiecare categorie. Această abordare tratează toate clasele cu importanță absolut egală. Reprezintă indicatorul principal de referință în evaluările medicale, deoarece previne mascarea erorilor de pe clasa patologică (minoritară) de către rezultatele bune obținute pe clasa pacienților sănătoși (majoritară).

- **Media Ponderată (Weighted Average):** Calculează media metricilor ținând cont de proporția (suportul) fiecărei clase în setul de testare. Deși reflectă bine performanța generală a sistemului pe volumul total de date, în situațiile cu dezechilibru sever între clase acest indicator trebuie interpretat cu precauție, deoarece este puternic influențat de performanța pe clasa majoritară.

Pe lângă metricile agregate prezentate anterior, o evaluare comprehensivă a unui model de clasificare medicală necesită analiza detaliată a matricelor de confuzie (*Confusion Matrices*). Matricea de confuzie este un instrument vizual și analitic fundamental care detaliază performanța algoritmului nu doar la nivel de acuratețe globală, ci la nivelul fiecărei intersecții dintre diagnosticul real (*Ground Truth*) și predicția modelului.

Structura sa permite extragerea a patru categorii esențiale de rezultate:

- **Adevărat Pozitiv (TP - True Positive):** Pacienți bolnavi identificați corect ca fiind bolnavi.
- **Adevărat Negativ (TN - True Negative):** Pacienți sănătoși identificați corect ca fiind sănătoși.
- **Fals Pozitiv (FP - False Positive - Eroare de tip I):** Pacienți sănătoși clasificați eronat ca având boala Alzheimer. Deși generează anxietate și costuri pentru teste suplimentare, în faza de *screening* este adesea considerată o eroare tolerabilă comparativ cu omiterea bolii.
- **Fals Negativ (FN - False Negative - Eroare de tip II):** Pacienți bolnavi clasificați drept sănătoși. În contextul medical, minimizarea acestei valori este critică, deoarece reprezintă un diagnostic ratat și pierderea ferestrei terapeutice pentru pacient.

Pentru a oferi o imagine completă, evaluarea pe fiecare set de date este însoțită de două reprezentări ale matricei de confuzie (exemplificate în Figura 6):

1. **Matricea nenormalizată (valori absolute):** Afișează numărul exact de volume RMN (pacienți) încadrate în fiecare categorie. Aceasta expune direct dezechilibrul claselor din setul de testare (ex. o proporție mult mai mare de subiecți sănătoși comparativ cu cei bolnavi).
2. **Matricea normalizată (procente per stadiu):** Transformă valorile absolute în procente raportate la totalul fiecărei clase reale (linia orizontală însumează 100%). Această reprezentare vizualizează direct metrica de Sensibilitate (*Recall*) pentru fiecare clasă independent, demonstrând capacitatea reală a rețelei de a depista patologia, fără ca rezultatul să fie mascat de numărul mare de pacienți sănătoși.

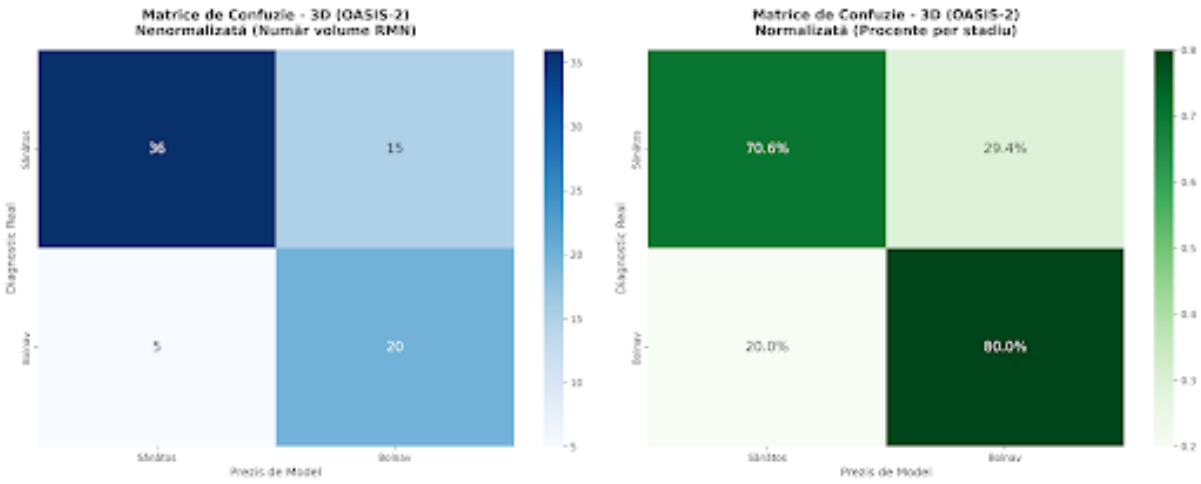


Figura 6: Exemplu de evaluare a modelului 3D pe setul de date OASIS-2. Stânga: Matricea de confuzie cu numărul absolut de predicții. Dreapta: Matricea normalizată, ilustrând o sensibilitate de 80.0% în depistarea pacienților cu declin cognitiv.

5.2 Performanța modelului și analiza matricelor de confuzie

Analizând rezultatele obținute pe setul de testare complet izolat din baza de date OASIS-3 (alcătuit exclusiv din volume 3D nevăzute de rețea în faza de antrenare), se remarcă un dezechilibru inerent al claselor. Această asimetrie reflectă cu fidelitate datele clinice reale dintr-un mediu spitalicesc de *screening*, unde proporția subiecților sănătoși o depășește categoric pe cea a pacienților cu neurodegenerare confirmată. Din cauza acestui fenomen, evaluarea performanței nu se poate baza exclusiv pe o acuratețe globală, care ar putea oferi o falsă impresie de eficiență prin simpla ghicire a clasei majoritare. Tabelul 1 sintetizează rapoartele finale de clasificare pentru acest scenariu.

Tabela 1: Raport de clasificare final pe setul de date OASIS-3 (3D)

Clasa	**Precision**	**Recall**	**F1-score**	**Support**
Sănătos	0.88	0.77	0.82	427
Bolnav	0.43	0.63	0.51	117
accuracy			0.74	544
macro avg	0.66	0.70	0.67	544
weighted avg	0.79	0.74	0.76	544

Din setul total de 544 de pacienți de test, distribuția a fost de 427 de instanțe pentru clasa „Sănătos" comparativ cu 117 pentru clasa „Bolnav". În acest context, modelul a obținut o specificitate (True Negative Rate) de aproximativ 77%, demonstrând o capacitate solidă de a identifica corect pacienții sănătoși cognitiv. Totodată, modelul a înregistrat o sensibilitate (True Positive Rate/Recall) de 63.2% pentru clasa de interes majoritar (bolnav). Această rată de detecție, obținută în pofida numărului redus de exemple pozitive disponibile la antrenament, indică o capacitate reală a arhitecturii de a extrage caracteristici patologice subtile din volumele

3D.

O analiză mai detaliată a acestor metrici relevă un compromis tehnic esențial, specific aplicațiilor de diagnostic medical asistat. Se observă că precizia pentru clasa „Bolnav" este de 0.43, ceea ce indică un număr ridicat de rezultate fals pozitive (pacienți clinic sănătoși clasificați eronat ca având afecțiunea). Acest fenomen nu este o simplă eroare a rețelei, ci rezultatul direct al strategiei de calibrare a pragului de decizie, orientată spre maximizarea sensibilității. Din perspectivă clinică, într-o etapă de screening, este preferabil ca sistemul să fie hipersensibil — generând alarme false ce pot fi ulterior analizate și infirmate de un medic specialist — decât să rateze un diagnostic real (eroare fals negativă).

De asemenea, deși confuziile între clasa minoritară și cea majoritară persistă din cauza suprapunerii vizuale masive dintre atrofia cerebrală incipientă și procesul natural de îmbătrânire, arhitectura dens conectată (precum modelul DenseNet121) reușește să mențină un echilibru funcțional, reflectat de o medie macro (Macro Average) de 0.67. Aceste rezultate demonstrează viabilitatea soluției și justifică explorarea ulterioară a unor tehnici avansate de compensare a dezechilibrului de date, precum augmentarea geometrică mai agresivă, sinteza datelor sau rafinarea arhitecturală la rezoluții de intrare superioare.

5.3 Provocări legate de eterogenitatea datelor: Analiza capacității de generalizare

O evaluare critică a performanței sistemului necesită testarea acestuia pe date provenite din surse externe. Rezultatele prezentate în Tabelul 2 evidențiază o provocare fundamentală în analiza imaginilor medicale: sensibilitatea arhitecturilor de învățare profundă la variabilitatea echipamentelor de achiziție.

Tabela 2: Degradarea performanței la transferul între diferite seturi de date (Domain Shift)

Set de date evaluat	**Macro Average**	**F1 Score**
OASIS-3 (Test intern)	0.70	0.74
ADNI (Test extern)	0.51	0.52

Evaluat pe setul de testare izolat din cohorta OASIS-3, modelul demonstrează o capacitate solidă de generalizare pe pacienți complet noi (aparținând aceleiași distribuții clinice), obținând un scor F1 de 0.74. Acest lucru confirmă că rețeaua a asimilat cu succes markerii vizuali asociați bolii Alzheimer, identificând corect tiparele de atrofie cerebrală. Cu toate acestea, performanța suferă o degradare severă (scor F1 de 0.52 și Macro Average de 0.51) atunci când același model este testat pentru prima dată pe baza de date ADNI.

Deși dispune de cunoștințele structurale necesare pentru a distinge pacienții sănătoși de cei bolnavi, modelul eșuează în a le transfera eficient. Motivul principal este faptul că rețeaua a memorat implicit „semnătura" tehnică a scannerelor utilizate în OASIS-3 (cum ar fi diferențele

fine de contrast, nivelul de zgomot specific sau calibrarea intensității). Astfel, deși rețeaua diferențiază precis patologia în mediul său nativ, diferențele hardware dintre protocoalele de scanare acționează ca un blocaj semnificativ în aplicarea acestor cunoștințe pe pacienți noi proveniți din afara cohortei inițiale, subliniind dificultatea fenomenului de *domain shift*.

Acest fenomen nu reprezintă o anomalie izolată a seturilor de date experimentale, ci o reflectare directă a realității din sistemul de sănătate global. În practica clinică, eterogenitatea tehnică a echipamentelor este inevitabilă și provine, în primul rând, din constrângerile bugetare specifice fiecărei unități medicale. Resursele financiare limitează adesea achiziția tehnologiilor de ultimă generație, ducând la coexistența aparatelor RMN mai vechi (cu câmp magnetic de 1.5 Tesla și o rezoluție mai slabă) cu sisteme moderne, ultra-performante (de 3 Tesla sau mai mult). La acești factori financiari se adaugă reglementările medicale specifice fiecărei țări, diversitatea producătorilor de echipamente hardware și protocoalele interne de calibrare ale clinicilor radiologice. În consecință, lipsa standardizării absolute a imaginilor la nivel global face ca orice model destinat utilizării clinice reale să fie nevoit să transceadă aceste bariere economice și administrative, izolând strict markerii neurodegenerării de zgomotul de fond al aparaturii.

5.4 Comparație cu performanțele raportate în literatura de specialitate

Pentru o validare obiectivă și riguroasă a sistemului informatic dezvoltat, este absolut esențială raportarea performanțelor obținute la rezultatele documentate recent în literatura de specialitate pentru aceeași bază de date. O astfel de analiză comparativă nu doar că plasează proiectul în contextul stadiului actual al artei (State of the Art), dar oferă și o perspectivă critică asupra provocărilor metodologice inerente. În acest sens, am realizat o comparație directă între acuratețea globală obținută de arhitectura propusă în această lucrare (având la bază rețeaua profundă DenseNet121) și performanța unui model similar de tip Rețea Neuronală Convoluțională (CNN) evaluat exclusiv pe setul de date OASIS-3, așa cum este raportat în studiul comprehensiv realizat de Balasundaram et al. [1].

Tabela 3: Comparație a acurateții obținute pe setul de date OASIS-3

Studiu / Model	**Set de date evaluat**	**Acuratețe raportată**
Model CNN standard (conform [1])	OASIS-3	83.30%
Arhitectura propusă (ResNet/DenseNet)	**OASIS-3 (Test set)**	**74.00%**

Analizând datele sintetizate în Tabelul 3, se observă o diferență de aproximativ 9 procente între acuratețea raportată în literatură (83.30%) și acuratețea globală obținută de modelul nostru (74.00%). Este imperativ de subliniat că această diferență nu indică neapărat o deficiență arhitecturală fundamentală a soluției noastre, ci subliniază mai degrabă complexitatea metodologică extremă a antrenării modelelor de *Deep Learning* pe date medicale brute.

Plafonarea performanței modelelor în intervalul 70%-84% pe seturi masive, profund eterogene și puternic dezechilibrate clinic, precum OASIS-3, este un fenomen bine documentat în rândul cercetătorilor. Această variație procentuală este pe deplin justificată de o serie de decizii metodologice divergente și de limitări tehnice specifice contextului acestui proiect.

În primul rând, un factor major de divergență, care face ca o comparație directă a acurateții absolute să fie asimetrică, constă în strategia de partiționare a datelor (*train/test split*). Deși ambele evaluări au la bază cohorta OASIS-3 și utilizează teoretic același raport procentual de împărțire a datelor, anume 80% pentru antrenare și 20% pentru testare, volumele RMN exacte care alcătuiesc aceste sub-seturi diferă complet. Datorită selecției aleatoare (randomizate) necesare pentru a asigura separarea strictă la nivel de subiect (*subject-level split*), eșantioanele de testare din cele două studii nu sunt identice. Astfel, este foarte probabil ca partiția de 20% generată în cadrul acestui proiect să fi inclus, pur aleatoriu, un număr mai mare de cazuri *borderline* (pacienți aflați la granița fină dintre procesul natural de îmbătrânire și declinul cognitiv foarte ușor), care sunt notoriu mai dificil de clasificat, ducând la o penalizare a acurateții globale. Fără un protocol de testare pe un set de date fix și standardizat universal pentru OASIS-3, variațiile de performanță sunt inerente și reflectă adesea dificultatea particulară a eșantionului extras, nu doar capacitatea pură a modelului.

În al doilea rând, un factor tehnic determinant îl reprezintă rezoluția spațială a datelor de intrare. Pentru a menține consumul de memorie VRAM și timpul de antrenare în limite fezabile pe infrastructura hardware disponibilă, arhitectura noastră a procesat volume 3D standardizate la o rezoluție scăzută, de $128 \times 128 \times 128$ voxeli. Studiile de referință din literatură exploatează adesea rezoluții net superioare (de exemplu, $256 \times 256 \times 256$ voxeli sau secțiuni 2D la rezoluție nativă), ceea ce le permite să capteze detalii micro-structurale mult mai fine. Prin reducerea dimensionalității în cazul nostru, o parte din granulația necesară identificării formelor subtile și incipiente de atrofie cerebrală a fost estompată.

În al treilea rând, deciziile luate pentru a aborda dezechilibrul sever al claselor au influențat direct metrica de acuratețe globală. În implementarea noastră, s-a optat deliberat pentru utilizarea ponderilor de penalizare (*class weights*) și calibrarea asimetrică a pragului de decizie, având ca intenție asumată forțarea rețelei să acorde o atenție sporită pacienților bolnavi. Această decizie clinică a sacrificat o proporție din instanțele clasei majoritare „Sănătos" (generând mai multe rezultate fals pozitive) pentru a maximiza detectarea cazurilor pozitive (sensibilitatea). Într-un context medical real, o acuratețe globală mare obținută prin ignorarea pacienților minoritari aflați în stadii de risc este ineficientă; prin urmare, scăderea matematică a acurateții este un compromis asumat în favoarea relevanței diagnosticului.

Prin urmare, deși acuratețea absolută obținută se află sub pragul maxim raportat de lucrările optimizate exclusiv pentru această metrică, arhitectura dezvoltată își atinge scopul propus. Ea validează funcționalitatea și robustețea întregului flux de procesare, demonstrează o sensibilitate promițătoare pentru clasa patologică și, cel mai important, evidențiază în mod transparent dificultățile tehnice fundamentale ale diagnosticului asistat pe cohorte clinice eterogene. Direcția principală pentru atingerea unor performanțe superioare rămâne, în mod evident,

scalarea infrastructurii hardware pentru procesarea volumelor la o rezoluție înaltă, alături de adoptarea unor protocoale standardizate de partiționare a datelor, precum validarea încrucișată în K pași (*k-fold cross-validation*), pentru a elimina complet variațiile statistice introduse de selecția aleatoare a partiției de testare.

6 CONCLUZII ȘI DEZVOLTĂRI ULTERIOARE

6.1 Concluzii

În cadrul acestei lucrări de diplomă, a fost proiectat, implementat și evaluat un pipeline avansat de învățare automată dedicat analizei imaginilor de rezonanță magnetică (RMN) pentru diagnosticarea asistată a bolii Alzheimer. Obiectivul principal a depășit simpla demonstrație teoretică a unui algoritm, concentrându-se pe crearea unui instrument decizional robust și validat clinic. Acest sistem a fost conceput pentru a identifica markerii structurali microscopici ai neurodegenerării, capabil să diferențieze pacienții sănătoși din punct de vedere cognitiv de cei aflați în stadii incipiente de boală. Astfel, lucrarea de față reprezintă un efort interdisciplinar de a transfera complexitatea inteligenței artificiale și a viziunii artificiale într-o soluție direct aplicabilă în sprijinul actului medical, eliminând o mare parte din subiectivitatea inerentă analizei umane tradiționale.

Pentru atingerea acestui scop, procesul de cercetare a implicat testarea, antrenarea și calibrarea unor arhitecturi de rețele neuronale convoluționale profunde din familiile DenseNet și ResNet. În mod particular, arhitectura DenseNet121 s-a dovedit a fi esențială în extragerea detaliilor fine din scanările medicale. Datorită conectivității sale dense, care facilitează reutilizarea caracteristicilor (*feature reuse*) și combate eficient problema dispariției gradientului (*vanishing gradient*), modelul a reușit să capteze modificări morfologice invizibile cu ochiul liber. Modelele au fost expuse unor seturi de date imagistice complexe și masive, cuprinzând atât secțiuni bidimensionale (2D), cât și volume tridimensionale (3D) de înaltă densitate informațională, extrase din cohorte clinice de referință la nivel internațional: seriile OASIS (versiunile 1, 2 și 3) și ADNI.

O componentă fundamentală și distinctivă a acestei cercetări a constituit-o evaluarea și compararea directă a acestor baze de date, fiecare prezentând avantaje și limitări specifice în contextul antrenării modelelor de *Deep Learning*. Experiențele inițiale efectuate pe OASIS-1 au demonstrat fezabilitatea clasificării pe cohorte mici de tip *cross-sectional*, permițând o prototipare rapidă a pipeline-ului de procesare, însă evidențiind o capacitate limitată de generalizare pe distribuții noi. Tranziția către OASIS-2 a introdus o perspectivă longitudinală, permițând teoretic observarea evoluției patologiei în timp pentru aceiași subiecți, dar demersul a fost constrâns de volumul global redus de pacienți disponibili.

Din acest motiv, baza de date OASIS-3 s-a impus ca pilonul central al etapei de antrenare și testare internă. Volumul său masiv și eterogenitatea datelor 3D au susținut convergența optimă a rețelelor profunde. Totuși, utilizarea acestui set a adus în prim-plan provocarea compensării dezechilibrului sever între numărul majoritar al pacienților sănătoși și cel minoritar al

pacienților cu declin cognitiv. Această problemă a fost abordată și atenuată prin implementarea unor tehnici avansate de optimizare, precum supraeșantionarea asimetrică, augmentarea spațială dinamică și ajustarea ponderilor de penalizare în funcția de cost. Nu în ultimul rând, validarea pe setul de date ADNI a funcționat ca test suprem de robustețe externă. Deși ADNI excelează printr-o standardizare clinică extrem de riguroasă și o granularitate fină a stadiilor bolii, a expus modelul la o nouă paradigmă tehnică, testându-i limitele de adaptabilitate.

Rezultatele globale obținute validează viabilitatea arhitecturilor alese și a fluxului de preprocesare propus. Modelul a demonstrat o capacitate solidă de a extrage caracteristici geometrice subtile, precum atrofia hipocampală sau subțierea materiei cenușii, obținând performanțe predictive ridicate—în special în maximizarea sensibilității (*Recall*)—atunci când datele de antrenare și testare provin din aceeași distribuție tehnică (OASIS-3). Sistemul reușește, astfel, să semnaleze cu o acuratețe promițătoare cazurile de patologie, un aspect critic pentru validitatea unui instrument de screening.

Totuși, o concluzie majoră a acestei evaluări comparative a evidențiat una dintre cele mai severe provocări din imagistica medicală modernă: sensibilitatea ridicată a modelelor de învățare profundă la variabilitatea hardware a echipamentelor de achiziție. Degradarea notabilă a performanței observată la tranziția bruscă de pe scannerele OASIS pe protocoalele ADNI subliniază un aspect tehnic fundamental. Deși rețeaua asimilează corect și memorează tiparele anatomice ale patologiei Alzheimer, eterogenitatea contrastului, zgomotul de fundal și diferențele de calibrare ale diverselor aparate RMN (fenomenul de *domain shift*) acționează ca un bruiaj informațional. Prin urmare, lucrarea demonstrează că, deși soluțiile algoritmice actuale sunt extrem de capabile, obstacolul major în calea generalizării perfecte și a implementării pe scară largă în mediul clinic real rămâne omogenizarea datelor și dezvoltarea unor arhitecturi complet invariante la dispozitivul de achiziție.

6.2 Dezvoltări ulterioare

Deși rezultatele curente demonstrează eficiența abordării propuse, complexitatea diagnosticului neuroimagistic oferă numeroase direcții de extindere și optimizare a procesului de cercetare.

Cea mai promițătoare direcție de dezvoltare o reprezintă scalarea rezoluției volumelor 3D procesate. În implementarea curentă, analiza a fost efectuată pe volume standardizate la o rezoluție de $128 \times 128 \times 128$ voxeli. Tranziția către o rezoluție superioară, precum $256 \times 256 \times 256$ voxeli, ar permite modelelor să capteze detalii structurale mult mai precise și profunde. O astfel de granularitate ar crește considerabil sensibilitatea rețelei la modificările micro-structurale incipiente (ex. subțierea corticală foarte ușoară), având potențialul de a îmbunătăți radical acuratețea diagnosticului.

Cu toate acestea, îmbunătățirea rezoluției introduce un compromis tehnic sever, definit în primul rând de limitările hardware. Pentru a ilustra concret acest impact, antrenarea modelului pe setul de date OASIS-3 la rezoluția curentă de $128 \times 128 \times 128$ voxeli, pe un standard de

100 de epoci, se realizează în 12-14 ore utilizând un accelerator grafic performant (NVIDIA RTX 4090). Dublarea rezoluției spațiale la $256 \times 256 \times 256$ voxeli extinde dramatic acest timp, ajungând la aproximativ 5 zile de procesare continuă pe aceeași infrastructură. Mai mult, o creștere suplimentară către o rezoluție mai mare crește exponențial amprenta de memorie VRAM necesară și ar prelungi timpul de antrenare la nivel de săptămâni sau chiar luni de zile pentru un singur experiment. Astfel, pentru a susține o asemenea rezoluție, procesul de cercetare va necesita o translatare de la stații de lucru individuale către o putere de calcul considerabilă, sub forma unor clastere multi-GPU de ultimă generație. Explorarea echilibrului dintre maximizarea preciziei clinice și limitările resurselor computaționale va constitui principalul obiectiv al iterărilor viitoare ale acestui proiect.

DECLARAȚIE PRIVIND DISPONIBILITATEA DATELOR

Seturile de date analizate în cadrul acestei lucrări sunt fie seturi de date cu acces public, fie date furnizate și utilizate la cerere, prin acceptarea consimțământului impus de proprietar și a acordurilor de utilizare, după cum urmează:

- **OASIS-1 și OASIS-2:** Sunt seturi de date complet publice, disponibile comunității științifice pentru descărcare și analiză fără restricții de tip consimțământ la cerere.
- **OASIS-3:** Datele au fost obținute la cerere, în urma semnării unui acord de utilizare a datelor (Data Use Agreement). Conform cerințelor de publicare impuse de proprietar, declarăm următoarele:
  Data were provided in part by OASIS-3: Principal Investigators: T. Benzinger, D. Marcus, J. Morris; NIH P50 AG005681, P30 NS09857781, P01 AG026276, P01 AG003991, R01 AG043434, UL1 TR000448, R01 EB009352. AV-45 doses were provided by Avid Radiopharmaceuticals, a wholly owned subsidiary of Eli Lilly.
- **ADNI (Alzheimer's Disease Neuroimaging Initiative):** Datele au fost obținute la cerere și aprobate de comitetul ADNI. Conform termenilor de utilizare acceptați, se fac următoarele precizări obligatorii:
  Data used in preparation of this article were obtained from the Alzheimer's Disease Neuroimaging Initiative (ADNI) database (adni.loni.usc.edu). As such, the investigators within the ADNI contributed to the design and implementation of ADNI and/or provided data but did not participate in the analysis or writing of this report. A complete listing of ADNI investigators can be found at:
  `http://adni.loni.usc.edu/wp-content/uploads/how_to_apply/ADNI_Acknowledgement_List.pdf`

  Data collection and sharing for the Alzheimer's Disease Neuroimaging Initiative (ADNI) is funded by the National Institute on Aging (National Institutes of Health Grant U19AG024904). The grantee organization is the Northern California Institute for Research and Education. In the past, ADNI has also received funding from the National Institute of Biomedical Imaging and Bioengineering, the Canadian Institutes of Health Research, and private sector contributions through the Foundation for the National Institutes of Health (FNIH) including generous contributions from the following: AbbVie, Alzheimer's Association; Alzheimer's Drug Discovery Foundation; Araclon Biotech; BioClinica, Inc.; Biogen; Bristol Myers Squibb Company; CereSpir, Inc.; Cogstate; Eisai Inc.; Elan Pharmaceuticals, Inc.; Eli Lilly and Company; EuroImmun; F. Hoffmann-La Roche Ltd and its affiliated company Genentech, Inc.; Fujirebio; GE Healthcare; IXICO Ltd.; Janssen Alzheimer Immunotherapy Research & Development, LLC.; Johnson & Johnson Pharmaceutical Research & Development LLC.; Lumosity; Lundbeck; Merck &

Co., Inc.; Meso Scale Diagnostics, LLC.; NeuroRx Research; Neurotrack Technologies; Novartis Pharmaceuticals Corporation; Pfizer Inc.; Piramal Imaging; Servier; Takeda Pharmaceutical Company; and Transition Therapeutics.

BIBLIOGRAFIE

[1] A Balasundaram, Sruthi Srinivasan, A Prasad, Jahan Malik, and Ayush Kumar. Hippocampus segmentation-based alzheimer's disease diagnosis and classification of mri images. *Arabian Journal for Science and Engineering*, 48:10249–10265, 2023.

[2] Michael W Weiner, Dallas P Veitch, Paul S Aisen, Laurel A Beckett, Nigel J Cairns, Robert C Green, Danielle Harvey, Clifford R Jack Jr, William Jagust, Enchi Liu, et al. The alzheimer's disease neuroimaging initiative: a review of papers published since its inception. *Alzheimer's & Dementia*, 11(7):e1–e120, 2015.

[3] Junhao Wen, Elina Thibeau-Sutre, Mauricio Diaz-Melo, Jorge Samper-González, Alexandre Routier, Simona Bottani, Didier Dormont, Stanley Durrleman, Ninon Burgos, and Olivier Colliot. Convolutional neural networks for classification of alzheimer's disease: Overview and reproducible evaluation. *Medical image analysis*, 66:101794, 2020.

[4] World Health Organization. Dementia - key facts, March 2025. Accesat: 12 Martie 2026.

A EXTRASE DE COD

În această anexă sunt prezentate fragmentele de cod cele mai relevante din punct de vedere metodologic pentru implementarea pipeline-ului de procesare și antrenare a rețelei DenseNet121 3D. Implementarea a fost realizată în limbajul Python, utilizând ecosistemul PyTorch și librăria MONAI.

```
# Utilizarea AdamW pentru o regularizare decuplata a ponderilor (L2 regularization)
optimizer = optim.AdamW(model.parameters(), lr=LR, weight_decay=1e-4)

# Programatorul ratei de invatare pe baza functiei matematice cosinus
scheduler = optim.lr_scheduler.CosineAnnealingLR(optimizer, T_max=EPOCHS, eta_min=1e-6)
```

Secvența de cod A.1: Configurarea optimizatorului AdamW și a scheduler-ului CosineAnnealingLR

```
# Extinderea asimetrica a claselor in faza de antrenare pentru compensarea dezechilibrului
if self.is_train:
    df_healthy_expanded = pd.concat([df_healthy] * healthy_multiplier, ignore_index=True)
    df_sick_expanded = pd.concat([df_sick] * sick_multiplier, ignore_index=True)
    self.df = pd.concat([df_healthy_expanded, df_sick_expanded], ignore_index=True)

# Definirea augmentarilor spatiale MONAI specifice clasei patologice (bolnav)
self.sick_augment = Compose([
    RandFlip(prob=0.5, spatial_axis=0),
    RandRotate(range_x=angle_15, range_y=angle_15, range_z=angle_15, prob=0.8),
    RandZoom(prob=0.3, min_zoom=0.9, max_zoom=1.1),
    RandGaussianNoise(prob=0.1, mean=0.0, std=0.1)
])
```

Secvența de cod A.2: Implementarea strategiei de supraeșantionare asimetrică (Asymmetric Oversampling) în clasa Dataset

```
# Calculul probabilitatilor prin aplicarea functiei Softmax pe
    output-ul brut al retelei
probs = torch.softmax(outputs.data, dim=1)
prob_bolnav = probs[:, 1]

# Ajustarea pragului clinic de detectie pentru optimizarea
    metricii de Recall
prag_medical = 0.3
predicted = (prob_bolnav >= prag_medical).long()
```

Secvența de cod A.3: Calibrarea pragului de decizie (Medical Thresholding) pentru maximizarea sensibilității predictive